



UCZELNIA LUDZI CIEKAWYCH

Studia podyplomowe Big Data — Analytics & Society

BARTOSZ PRZYBYSZ

Projekt i implementacja systemu wspomagania analizy spożycia składników odżywczych z wykorzystaniem metod Retrieval-Augmented Generation

Na przykładzie danych NHANES oraz literatury
naukowej pozyskanej z bazy PubMed

Praca dyplomowa

Promotor: dr Łukasz Wawrowski

Poznań 2026

Spis treści

Wstęp	4
1 Charakterystyka zbioru NHANES	7
1.1 Przygotowanie danych	8
1.2 Ekspolaryjna analiza danych	9
1.2.1 Wnioski z analizy eksploracyjnej	11
1.3 Podsumowanie rozdziału	12
2 Projekt systemu wspomagania analizy żywieniowej	13
2.1 Założenia funkcjonalne systemu	13
2.2 Architektura rozwiązania	14
2.3 Technologie i koncepcje wykorzystane w pracy	17
2.3.1 Przetwarzanie języka naturalnego	17
2.3.2 Reprezentacje wektorowe i embeddingi	17
2.3.3 Duże modele językowe	17
2.3.4 Architektura Retrieval-Augmented Generation	18
2.4 Przegląd istniejących rozwiązań	18
2.5 Architektura bazy wiedzy	19
2.6 Proces generowania raportu	21
2.7 Ograniczenia systemu	22
3 Implementacja systemu	23
3.1 Weryfikacja działania systemu	25
3.2 Podsumowanie rozdziału	28
Podsumowanie	30
4 Bibliografia	32

Spis rycin

1.1	Struktura wiekowa respondentów w badaniu NHANES	10
2.1	Diagram architektury systemu	15

Spis tabel

1.1	Wyniki analizy spożycia błonnika pokarmowego w badanej populacji	10
1.2	Wyniki analizy spożycia sodu w badanej populacji	11
3.1	Publikacje naukowe zwrócone przez moduł Retrieval dla scenariusza niedoboru błonnika	26
3.2	Publikacje naukowe zwrócone przez moduł Retrieval dla scenariusza nad- miernego spożycia sodu	27

Wstęp

Odżywianie jest nieodłącznym elementem życia. Człowiek musi jeść by przeżyć. Wraz z pokarmem, człowiek powinien dostarczać odpowiedniej ilości energii oraz składników odżywczych. Jest to niezbędne do prawidłowego funkcjonowania procesów biologicznych, utrzymania sprawności organizmu oraz zmniejszania ryzyka występowania wielu chorób przewlekłych. Zarówno niedobory, jak i nadmiary składników odżywczych mogą prowadzić do negatywnych konsekwencji zdrowotnych, które często ujawniają się po wielu latach.

Współczesne społeczeństwa mają dostęp do coraz większej ilości informacji dotyczących zdrowego stylu życia oraz zasad prawidłowego żywienia. Pomimo tego nieprawidłowe nawyki żywieniowe nadal pozostają istotnym problemem zdrowia publicznego. Niewłaściwa dieta jest uznawana za jeden z czynników ryzyka wielu schorzeń, takich jak choroby układu krążenia, cukrzyca typu 2, nadciśnienia tętnicze czy otyłość. Z tego względu monitorowanie sposobu żywienia społeczeństwa stanowi ważny element działań podejmowanych przez instytucje zajmujące się zdrowiem publicznym.

Ocena stanu odżywiania populacji wymaga gromadzenia oraz analizy dużych ilości danych dotyczących spożycia żywności i składników odżywczych. W tym celu prowadzone są badania populacyjne pozwalające na identyfikację najczęściej występujących problemów żywieniowych oraz obserwację zmian zachodzących w czasie. Wyniki takich analiz mogą stanowić podstawę do opracowywania programów edukacyjnych, kampanii profilaktycznych oraz rekomendacji żywieniowych kierowanych do różnych grup społecznych.

Wraz ze wzrostem ilości dostępnych danych rośnie znaczenie narzędzi informatycznych wspomagających proces ich analizy. Nowoczesne metody analizy danych umożliwiają identyfikację trendów żywieniowych, wykrywanie nieprawidłowości oraz wspieranie ekspertów w procesie podejmowania decyzji. Szczególnego znaczenia nabierają rozwiązania wykorzystujące sztuczną inteligencję oraz automatyczne przetwarzanie informacji naukowej, które mogą przyspieszyć interpretację wyników i ułatwić dostęp do aktualnej wiedzy medycznej.

Pomimo dostępności dużych zbiorów danych żywieniowych oraz obszernej literatury naukowej, proces identyfikacji problemów żywieniowych i ich interpretacji nadal wymaga znacznego nakładu pracy ekspertów. Analitycy zdrowia publicznego oraz specjaliści z zakresu żywienia muszą nie tylko analizować dane dotyczące spożycia składników odżywczych, ale również interpretować wyniki w kontekście aktualnej wiedzy naukowej. W praktyce oznacza

to konieczność równoczesnej pracy z danymi statystycznymi oraz przeglądania licznych publikacji naukowych.

Analiza dużych zbiorów danych populacyjnych pozwala na identyfikację niedoborów i nadmiarów składników odżywczych występujących w określonych grupach społecznych. Samo wykrycie problemu nie jest jednak wystarczające do sformułowania wniosków oraz rekomendacji. Konieczne jest również odniesienie wyników do aktualnych badań naukowych opisujących potencjalne skutki zdrowotne obserwowanych zjawisk. Proces ten jest czasochłonny i wymaga specjalistycznej wiedzy zarówno z zakresu żywienia, jak i wyszukiwania oraz oceny jakości literatury naukowej.

Dodatkowym wyzwaniem jest dynamiczny wzrost liczby publikacji naukowych. Bazy takie jak PubMed zawierają miliony artykułów, a każdego roku publikowane są kolejne tysiące prac dotyczących zdrowia i żywienia człowieka. W efekcie ręczne wyszukiwanie najbardziej istotnych publikacji oraz synteza zawartych w nich informacji stają się coraz bardziej wymagające.

Rozwój metod sztucznej inteligencji, w szczególności dużych modeli językowych (Large Language Models, LLM), stwarza nowe możliwości wspomagania procesu analizy danych oraz interpretacji wyników. Szczególne zainteresowanie budzą rozwiązania wykorzystujące architekturę Retrieval-Augmented Generation (RAG), która pozwala łączyć generowanie tekstu przez model językowy z informacjami pochodzącymi z zewnętrznej bazy wiedzy. Takie podejście umożliwia tworzenie raportów opartych zarówno na danych wejściowych, jak i aktualnej literaturze naukowej.

W związku z przedstawionymi wyzwaniami sformułowano następujące pytanie badawcze: **W jaki sposób można wykorzystać architekturę Retrieval-Augmented Generation do wspomagania analizy spożycia składników odżywczych oraz generowania raportów opartych na danych żywieniowych i literaturze naukowej?**

Celem niniejszej pracy jest zaprojektowanie oraz implementacja systemu wspomagania analizy spożycia składników odżywczych z wykorzystaniem metod Retrieval-Augmented Generation. Opracowane rozwiązanie ma wspierać analityków zdrowia publicznego w identyfikacji niedoborów i nadmiarów składników odżywczych występujących w badanej populacji oraz dostarczać informacje oparte na aktualnej literaturze naukowej. W ramach pracy opracowano system umożliwiający analizę danych żywieniowych, automatyczne wykrywanie problemów związanych ze spożyciem wybranych składników odżywczych oraz generowanie raportów wspomagających proces interpretacji wyników. Generowane raporty łączą informacje pochodzące z analizowanego zbioru danych z wiedzą pozyskiwaną z publikacji naukowych.

Hipoteza badawcza zakłada, że zastosowanie architektury Retrieval-Augmented Generation umożliwia skuteczne połączenie wyników analizy danych żywieniowych z aktualną literaturą naukową oraz pozwala na automatyczne generowanie raportów wspierających

interpretację wyników i identyfikację potencjalnych zagrożeń zdrowotnych związanych ze sposobem żywienia populacji. Zakres przedmiotowy pracy obejmuje analizę spożycia składników odżywczych, wykorzystanie metod wyszukiwania semantycznego, budowę bazy wiedzy opartej na publikacjach naukowych oraz zastosowanie dużych modeli językowych do generowania raportów. Zakres przestrzenny obejmuje dane pochodzące z badania NHANES realizowanego na terenie Stanów Zjednoczonych. Zakres czasowy obejmuje dane NHANES z cyklu badawczego 2017–2018 oraz publikacje naukowe pozyskane z bazy PubMed na potrzeby budowy bazy wiedzy.

Praca składa się z trzech rozdziałów. W pierwszym rozdziale przedstawiono charakterystykę wykorzystanych danych oraz przeprowadzono analizę spożycia wybranych składników odżywczych. W drugim rozdziale opisano założenia i architekturę opracowanego systemu oraz proces budowy bazy wiedzy. W trzecim rozdziale przedstawiono implementację rozwiązania oraz wyniki weryfikacji jego działania.

1 Charakterystyka zbioru NHANES

NHANES to ogólnokrajowe badanie zdrowia i stanu odżywiania populacji prowadzone w Stanach Zjednoczonych (Centers for Disease Control and Prevention, n.d.). Program jest realizowany przez National Center for Health Statistics, będąc częścią Centers for Disease Control and Prevention (CDC). Badanie zostało uruchomione na początku lat 60. XX wieku, natomiast od 1999 roku jest prowadzone w sposób ciągły. Głównym celem NHANES jest monitorowanie stanu zdrowia społeczeństwa amerykańskiego. NHANES łączy dane pochodzące z wywiadów ankietowych, badań lekarskich oraz analiz laboratoryjnych. Zbierane są informacje dotyczące między innymi demografii, sposobu odżywiania, aktywności fizycznej i występowania chorób. Badanie obejmuje reprezentatywną próbe mieszkańców Stanów Zjednoczonych. Dzięki temu uzyskane wyniki mogą być uogólniane na całą populację kraju. NHANES wyróżnia się wysoką jakością danych oraz standaryzacją procesu ich zbierania. Z tego względu jest jednym z najczęściej wykorzystywanych źródeł danych w badaniach epidemiologicznych, medycznych i z zakresu zdrowia publicznego (Zipf et al., 2013).

W ramach projektu wykorzystano dwa zbiory danych pochodzące z cyklu NHANES 2017-2018:

- DEMO_J
- DR1TOT_J

Tabela DEMO_J zawiera informacje demograficzne dotyczące uczestników badania, takie jak wiek oraz płeć (National Center for Health Statistics, 2017). Z kolei tabela DR1TOT_J zawiera dane dotyczące spożycia składników odżywczych uzyskane na podstawie pierwszego 24-godzinnego wywiadu żywieniowego (Day 1 Total Nutrient Intakes) (National Center for Health Statistics, 2018). Połączenie obu zbiorów umożliwia analizę spożycia składników odżywczych w kontekście cech demograficznych badanej populacji.

W projekcie wykorzystano wybrane zmienne niezbędne do przeprowadzenia analiz żywieniowych oraz budowy systemu wspomagania decyzji.

- SEQN - unikalny identyfikator uczestnika badania

- RIAGENDR - płeć uczestnika
- RIDAGEYR - wiek uczestnika w latach
- DR1DRSTZ - status wiarygodności wywiadu żywieniowego
- DR1MRESP - osoba odpowiadająca na pytania ankietowe
- DR1HELP - informacja o pomocy udzielanej podczas wywiadu
- DR1TKCAL - dzienne spożycie energii [kcal]
- DR1TFIBE - dzienne spożycie błonnika (g)
- DR1TSODI - dzienne spożycie sodu (mg)

Przedstawione zmienne zostały wykorzystane podczas przygotowania danych oraz dalszej analizy spożycia składników odżywczych.

Oba zbiory danych zostały połączone przy wykorzystaniu identyfikatora uczestnika SEQN. W wyniku połączenia uzyskano zbiór zawierający 8704 obserwacje. Każda obserwacja reprezentuje pojedynczego uczestnika badania. Otrzymany zbiór stanowi podstawę dalszych etapów przetwarzania danych, tworzenia zmiennych pomocniczych oraz analiz przedstawionych w kolejnych częściach pracy.

Zbiór NHANES został wybrany ze względu na wysoką jakość danych, szeroki zakres gromadzonych informacji oraz powszechne wykorzystanie w badaniach naukowych. Dane zawierają szczegółowe informacje dotyczące spożycia składników odżywczych, co umożliwia przeprowadzenie analiz związanych z identyfikacją niedoborów i nadmiarów żywieniowych.

Dodatkową zaletą jest możliwość łączenia informacji pochodzących z różnych modułów badania przy wykorzystaniu wspólnego identyfikatora uczestnika. Pozwala to na tworzenie bardziej kompleksowych zbiorów danych oraz rozszerzenie analiz o kolejne aspekty zdrowia i żywienia w przyszłych etapach rozwoju systemu.

1.1 Przygotowanie danych

Przed rozpoczęciem analizy przeprowadzono kontrolę jakości danych. Zweryfikowano występowanie zduplikowanych rekordów oraz brakujących wartości. Nie wykryto zduplikowanych obserwacji w żadnym z analizowanych zbiorów danych. Przeprowadzona analiza brakujących wartości wykazała ich zgodność z dokumentacją NHANES. Występujące braki

wynikały ze sposobu projektowania badania oraz logiki ankiety, a nie z błędów podczas gromadzenia danych.

W pierwszym etapie przygotowania danych połączono tabele DEMO_J oraz DR1TOT_J. Obie tabele zawierają wspólny identyfikator uczestnika badania oznaczony jako SEQN, który został wykorzystany jako klucz łączenia. W wyniku połączenia uzyskano zbiór zawierający 8704 obserwacje oraz 11 zmiennych.

Na potrzeby dalszej analizy utworzono zmienną pomocniczą umożliwiającą klasyfikację uczestników badania ze względu na deklarowane dzienne spożycie energii. Celem było zidentyfikowanie obserwacji charakteryzujących się skrajnie niską lub skrajnie wysoką kalorycznością, które mogłyby wpływać na wyniki dalszych analiz. Na potrzeby projektu przyjęto zakres od 800 do 5500 kcal jako przedział reprezentujący typowe dzienne spożycie energii. Obserwacje znajdujące się poza tym zakresem zostały oznaczone jako potencjalnie niereprezentatywne i wykorzystane w dalszym procesie filtrowania danych.

W celu zwiększenia wiarygodności analiz utworzono dodatkowy filtr jakości danych. Pozostawiono wyłącznie obserwacje spełniające określone kryteria jakościowe. Do dalszej analizy zakwalifikowano uczestników, których wywiad żywieniowy został oznaczony jako wiarygodny przez NHANES, którzy samodzielnie odpowiadali na pytania lub odpowiadali za żywienie gospodarstwa domowego oraz nie wymagali pomocy podczas udzielania odpowiedzi. Dodatkowo odrzucono obserwacje o skrajnie niskiej lub wysokiej deklarowanej podaży energii. Na potrzeby projektu przyjęto zakres od 800 do 5500 kcal jako przedział reprezentujący typowe dzienne spożycie energii. Z analizy wykluczono również niemowlęta i dzieci do ukończenia 2. roku życia. W ramach pracy przyjęto osoby w wieku powyżej 2 lat, ponieważ sposób żywienia najmłodszych dzieci istotnie różni się od pozostałych grup wiekowych i wymaga odrębnych kryteriów oceny. Końcowy zbiór analityczny został zapisany w tabeli nhanes_gold i stanowi źródło danych wykorzystywane przez moduł analizy statystycznej systemu.


Proces przygotowania danych obejmował integrację danych demograficznych i żywieniowych, kontrolę jakości danych, filtrowanie obserwacji oraz utworzenie zmiennych pomocniczych wykorzystywanych przez system. W wyniku przeprowadzonych operacji utworzono końcowy zbiór analityczny stanowiący podstawę dalszych analiz oraz działania opracowanego rozwiązania.

1.2 Ekspolaryjna analiza danych

Po przygotowaniu końcowego zbioru analitycznego przeprowadzono eksploracyjną analizę danych. Jej celem było poznanie podstawowych cech analizowanej populacji oraz iden-

tyfikacja potencjalnych problemów żywieniowych związanych ze spożyciem błonnika i sodu.

W pierwszej kolejności przeanalizowałem strukturę demograficzną uczestników badania - wynik przedstawiono na wykresie (Rysunek 1.1).



Rysunek 1.1: Struktura wiekowa respondentów w badaniu NHANES

Po przygotowaniu końcowego zbioru analitycznego przeprowadzono analizę spożycia błonnika pokarmowego. W pierwszej kolejności obliczono podstawowe statystyki opisowe. W celu lepszej wizualizacji rozkładu spożycia błonnika przygotowano tabelę z wynikami (Tabela 1.1).

Tabela 1.1: Wyniki analizy spożycia błonnika pokarmowego w badanej populacji

Miara	Wartość
Mediana [g]	14.3
90. percentyl [g]	29.3
Udział osób z niedoborem [%]	72.4
Udział osób w normie [%]	24.1
Udział osób z nadmiarem [%]	3.5

Mediana spożycia błonnika wyniosła 14,3g dziennie, co oznacza, że połowa uczestników badania spożywała mniej niż tę wartość. Dziewięćdziesiąty percentyl osiągnął wartość 29,3 g, wskazując na stosunkowo niewielką grupę osób spożywających większe ilości błonnika.

Analiza klasyfikacji uczestników wykazała, że około 72,4% badanych zostało zakwalifikowanych do grupy charakteryzującej się niedostatecznym spożyciem błonnika. Jedynie 24,1% uczestników osiągało poziom mieszczący się w przyjętym zakresie prawidłowego spożycia, natomiast nadmiar błonnika występował sporadycznie. Uzyskane wyniki wskazują że, niedobór błonnika może stanowić istotny problem żywieniowy w analizowanej populacji Veronese et al. (2025).

Kolejnym analizowanym składnikiem odżywczym był sód. Analogicznie do błonnika obliczono podstawowe statystyki opisowe. Tabela 1.2 przedstawia wyniki analizy spożycia sodu

Tabela 1.2: Wyniki analizy spożycia sodu w badanej populacji

Miara	Wartość
Mediana [mg]	3091.0
90. percentyl [mg]	5704.0
Udział osób z niedoborem [%]	7.7
Udział osób w normie [%]	11.3
Udział osób z nadmiarem [%]	81.0

Mediana spożycia sodu wyniosła 3091 mg dziennie, natomiast dziewięćdziesiąty percentyl osiągnął wartość 5704 mg. Otrzymane wyniki wskazują na występowanie znacznej liczby osób spożywających bardzo duże ilości sodu.

Analiza klasyfikacji wykazała, że około 81% uczestników badania zostało zakwalifikowanych do grupy nadmiernego spożycia sodu. Prawidłowy poziom spożycia odnotowano jedynie u około 11,3% badanych, natomiast niedobór występował u około 7,7% uczestników. Uzyskane wyniki sugerują, że nadmierne spożycie sodu stanowi istotny problem zdrowotny w analizowanej populacji (Bailey & Dhaun, 2024; World Health Organization, 2026).

1.2.1 Wnioski z analizy eksploracyjnej

Przeprowadzona analiza eksploracyjna wykazała występowanie dwóch wyraźnych problemów żywieniowych w analizowanej populacji. Z jednej strony zaobserwowano bardzo wysoki odsetek osób spożywających niewystarczające ilości błonnika, z drugiej natomiast znaczący udział uczestników charakteryzujących się nadmiernym spożyciem sodu.

Wyniki te pokazują, że analiza danych reprezentacyjnych pozwala skutecznie identyfikować potencjalne problemy żywieniowe. Same statystyki opisowe nie dostarczają jednak informacji o możliwych konsekwencjach zdrowotnych obserwowanych zjawisk. Aby właściwie interpretować uzyskane wyniki, konieczne jest odniesienie ich do aktualnej wiedzy naukowej oraz publikacji opisujących wpływ poszczególnych składników odżywczych na zdrowie człowieka.

Przedstawione ograniczenie stanowi podstawę do opracowania systemu wykorzystującego architekturę Retrieval-Augmented Generation, którego zadaniem jest wspomaganie analityka poprzez automatyczne wyszukiwanie publikacji naukowych oraz generowanie raportów opartych zarówno na danych statystycznych, jak i aktualnej literaturze naukowej.

1.3 Podsumowanie rozdziału

W rozdziale przedstawiono problematykę zdrowia publicznego w kontekście żywienia oraz znaczenie analizy danych populacyjnych w identyfikacji problemów związanych ze spożyciem składników odżywczych. Omówiono również charakterystykę badania NHANES, wykorzystane źródła danych oraz proces przygotowania końcowego zbioru analitycznego wykorzystywanego w dalszej części pracy. Przeprowadzona analiza eksploracyjna wykazała występowanie istotnych problemów żywieniowych w analizowanej populacji. Zaobserwowano bardzo wysoki odsetek osób charakteryzujących się niedostatecznym spożyciem błonnika oraz znaczący udział uczestników przekraczających przyjęte wartości referencyjne dla spożycia sodu. Wyniki te wskazują, że analiza danych populacyjnych pozwala skutecznie identyfikować potencjalne obszary wymagające dalszej uwagi specjalistów z zakresu zdrowia publicznego i żywienia.

Jednocześnie sama analiza statystyczna nie dostarcza informacji o możliwych konsekwencjach zdrowotnych obserwowanych zjawisk. Interpretacja wyników wymaga odniesienia do aktualnej wiedzy naukowej oraz publikacji opisujących wpływ poszczególnych składników odżywczych na zdrowie człowieka. W związku z tym zasadne jest opracowanie narzędzi wspomagających proces wyszukiwania literatury naukowej oraz generowania raportów interpretujących wyniki analiz.

W kolejnym rozdziale przedstawiono projekt systemu wykorzystującego architekturę Retrieval-Augmented Generation, którego zadaniem jest wspomaganie analityków zdrowia publicznego poprzez automatyczne wyszukiwanie publikacji naukowych oraz generowanie raportów opartych na danych populacyjnych i aktualnej literaturze naukowej.

2 Projekt systemu wspomagania analizy żywieniowej

W poprzednim rozdziale przedstawiono problematykę zdrowia publicznego związaną ze spożyciem składników odżywczych oraz przeprowadzono analizę danych pochodzących z badania NHANES. Uzyskane wyniki wskazały na występowanie istotnych problemów żywieniowych, takich jak niedostateczne spożycie błonnika oraz nadmierne spożycie sodu w analizowanej populacji.

Sama analiza statystyczna nie pozwala jednak na pełną interpretację uzyskanych wyników. Ocena potencjalnych konsekwencji zdrowotnych wymaga odniesienia obserwowanych zjawisk do aktualnej wiedzy naukowej. W praktyce oznacza to konieczność wyszukiwania odpowiednich publikacji naukowych oraz analizy zawartych w nich informacji, co jest procesem czasochłonnym i wymagającym specjalistycznej wiedzy.

W odpowiedzi na przedstawione wyzwania zaprojektowano system wspomagający analizę spożycia składników odżywczych wykorzystujący architekturę Retrieval-Augmented Generation. System łączy dane statystyczne pochodzące z badania NHANES z informacjami pozyskanymi z literatury naukowej zgromadzonej w dedykowanej bazie wiedzy. Celem rozwiązania jest automatyzacja procesu wyszukiwania publikacji naukowych oraz generowania raportów wspierających interpretację wyników analiz żywieniowych.

W dalszej części rozdziału przedstawiono założenia funkcjonalne systemu, architekturę rozwiązania, sposób budowy bazy wiedzy oraz proces generowania raportów.

2.1 Założenia funkcjonalne systemu

Celem opracowanego systemu jest wspomaganie analizy spożycia składników odżywczych poprzez automatyczne generowanie raportów opartych na danych populacyjnych oraz aktualnej literaturze naukowej. System został zaprojektowany jako narzędzie wspierające specjalistów zajmujących się analizą danych zdrowotnych, żywieniem oraz zdrowiem publicznym.

Podstawowym zadaniem systemu jest identyfikacja potencjalnych problemów żywieniowych występujących w analizowanej populacji oraz dostarczanie informacji naukowych umożliwiających interpretację uzyskanych wyników. W przeciwieństwie do tradycyjnych analiz statystycznych rozwiązanie nie ogranicza się wyłącznie do prezentowania wartości liczbowych, lecz wykorzystuje również publikacje naukowe w celu wyjaśnienia znaczenia obserwowanych zjawisk.

Dane wejściowe systemu stanowią informacje dotyczące spożycia wybranych składników odżywczych pochodzące z przygotowanego zbioru analitycznego NHANES. Na podstawie tych danych wyznaczane są podstawowe statystyki opisowe oraz określany jest charakter problemu żywieniowego, na przykład niedobór lub nadmierne spożycie analizowanego składnika.

Wyniki analizy statystycznej wykorzystywane są następnie do wyszukania odpowiednich publikacji naukowych w dedykowanej bazie wiedzy utworzonej na podstawie artykułów pozyskanych z bazy PubMed. System identyfikuje najbardziej istotne publikacje związane z analizowanym problemem, a następnie wykorzystuje je podczas generowania raportu końcowego.


Rezultatem działania systemu jest raport tekstowy zawierający podsumowanie wyników analizy statystycznej oraz interpretację opartą na aktualnej literaturze naukowej. Raport ma wspierać użytkownika w ocenie skali problemu żywieniowego oraz stanowić punkt wyjścia do dalszej analizy eksperckiej.

Przykładowy scenariusz użycia systemu zakłada analizę spożycia błonnika pokarmowego w badanej populacji. System oblicza statystyki opisowe, określa udział osób charakteryzujących się niedoborem błonnika, wyszukuje publikacje naukowe dotyczące konsekwencji zdrowotnych niewystarczającego spożycia tego składnika, a następnie generuje raport zawierający interpretację uzyskanych wyników wraz z odniesieniem do literatury naukowej.

2.2 Architektura rozwiązania

System został zaprojektowany jako rozwiązanie łączące analizę danych populacyjnych z mechanizmami wyszukiwania literatury naukowej oraz generowania tekstu przy użyciu dużych modeli językowych. Architektura systemu składa się z modułów odpowiedzialnych za przygotowanie danych, budowę bazy wiedzy, wyszukiwanie publikacji naukowych oraz generowanie raportów.

Głównym założeniem architektury było rozdzielenie procesu przygotowania bazy wiedzy od procesu generowania raportów. Kosztowne operacje związane z pozyskiwaniem publikacji, przetwarzaniem ich treści oraz generowaniem reprezentacji wektorowych wykonywane są jednorazowo podczas budowy bazy wiedzy, co znacząco skraca czas generowania raportów.



Rysunek 2.1: Diagram architektury systemu

System składa się z dwóch głównych części: procesu budowy bazy wiedzy oraz procesu generowania raportów. Diagram przepływu przedstawiony jest na Rysunek 2.1. Rozdzielenie tych etapów pozwala na jednorazowe przygotowanie zasobów wiedzy wykorzystywanych później podczas generowania raportów dla użytkownika.

Proces budowy bazy wiedzy rozpoczyna się od pozyskania publikacji naukowych z bazy PubMed. Artykuły wyszukiwane są przy użyciu wcześniej zdefiniowanych zapytań związanych z analizowanymi składnikami odżywczymi. Następnie pobierane są metadane publikacji, takie jak tytuł, abstrakt, rok publikacji oraz typ badania. Na tym etapie wykonywana jest również wstępna ocena jakości publikacji oparta na rodzaju artykułu naukowego oraz dacie publikacji.

Pozyskane artykuły są następnie przetwarzane przy wykorzystaniu dużego modelu językowego. Zadaniem tego etapu jest wzbogacenie danych o dodatkowe metadane umożliwiające ocenę przydatności publikacji z punktu widzenia analizy żywieniowej. Model językowy identyfikuje między innymi rodzaj badanej populacji oraz generuje dodatkowe informacje wykorzystywane podczas wyznaczania końcowej oceny jakości artykułu.

Kolejnym etapem jest utworzenie reprezentacji wektorowych dla treści publikacji (OpenAI, 2025). Wygenerowane embeddingi wraz z metadanymi zapisywane są w bazie PostgreSQL rozszerzonej o mechanizm pgvector Katz (2025). Tak przygotowana baza wiedzy umożliwia późniejsze wyszukiwanie semantyczne publikacji naukowych na podstawie znaczenia zapytania, a nie wyłącznie dopasowania słów kluczowych (Reimers & Gurevych, 2019).

Równolegle przygotowany jest zbiór danych populacyjnych pochodzących z badania NHANES. Dane przechodzą proces czyszczenia, filtrowania oraz transformacji, którego rezultatem jest końcowy zbiór analityczny wykorzystywany przez moduł statystyczny systemu. Na podstawie tych danych obliczane są statystyki opisowe pozwalające określić skalę analizowanego problemu żywieniowego.

Proces generowania raportu rozpoczyna się od identyfikacji analizowanego składnika odżywczego oraz charakteru problemu żywieniowego, na przykład niedoboru lub nadmiernego spożycia. Na tej podstawie tworzona jest reprezentacja zapytania wykorzystywana przez moduł wyszukiwania publikacji. System wykonuje wyszukiwanie semantyczne w bazie wiedzy, a następnie przeprowadza dodatkowy etap rankingu uwzględniający zarówno podobieństwo semantyczne, jak i ocenę jakości publikacji.

Najwyżej ocenione artykuły naukowe zostają połączone z wynikami analizy statystycznej pochodzącej ze zbioru NHANES. Tak przygotowany kontekst przekazywany jest do modelu językowego odpowiedzialnego za wygenerowanie raportu końcowego. Raport zawiera podsumowanie wyników analizy, interpretację obserwowanych zjawisk oraz informacje pochodzące z aktualnej literatury naukowej wraz ze wskazaniem wykorzystanych źródeł.

Przedstawiona architektura umożliwia oddzielenie procesu przygotowania bazy wiedzy od procesu generowania raportów. Dzięki temu system może wykorzystywać wcześniej przygotowane publikacje naukowe oraz reprezentacje wektorowe, ograniczając liczbę operacji wykonywanych podczas generowania raportu. Takie podejście zwiększa wydajność rozwiązania oraz pozwala na łatwe rozszerzanie bazy wiedzy o kolejne publikacje naukowe.

2.3 Technologie i koncepcje wykorzystane w pracy

2.3.1 Przetwarzanie języka naturalnego

Przetwarzanie języka naturalnego (ang. *Natural Language Processing*, NLP) stanowi dziedzinę sztucznej inteligencji zajmującą się analizą, interpretacją oraz generowaniem tekstu w języku naturalnym przez systemy komputerowe. Metody NLP umożliwiają automatyczne przetwarzanie dużych zbiorów dokumentów tekstowych, ekstrakcję informacji, klasyfikację treści oraz wyszukiwanie semantyczne (Jurafsky & Martin, 2025). W ostatnich latach dynamiczny rozwój modeli opartych na architekturze Transformer znacząco zwiększył możliwości systemów NLP, umożliwiając realizację złożonych zadań wymagających rozumienia kontekstu tekstowego (Vaswani et al., 2017).

2.3.2 Reprezentacje wektorowe i embeddingi

W celu umożliwienia komputerowej analizy tekstu dokumenty muszą zostać przekształcone do postaci numerycznej. Współczesne systemy NLP wykorzystują w tym celu reprezentacje wektorowe określane jako embeddingi. Embedding jest wielowymiarowym wektorem liczbowym opisującym znaczenie semantyczne fragmentu tekstu (OpenAI, 2025). Dokumenty o zbliżonej tematyce posiadają podobne reprezentacje wektorowe, co umożliwia realizację wyszukiwania semantycznego (Reimers & Gurevych, 2019). Embeddingi stanowią podstawę działania systemów Retrieval-Augmented Generation oraz wektorowych baz danych (Katz, 2025; Lewis et al., 2020).

2.3.3 Duże modele językowe

Duże modele językowe (ang. *Large Language Models*, LLM) są modelami sztucznej inteligencji trenowanymi na bardzo dużych zbiorach tekstów. Ich zadaniem jest modelowanie zależności występujących w języku naturalnym oraz generowanie spójnych odpowiedzi na podstawie dostarczonego kontekstu (Brown et al., 2020). Współczesne modele językowe, takie jak GPT, wykorzystują architekturę Transformer, która umożliwia efektywne modelowanie długodystansowych zależności pomiędzy elementami tekstu (Vaswani et al., 2017).

Modele te znajdują zastosowanie między innymi w systemach dialogowych, wyszukiwaniu informacji, analizie dokumentów oraz wspomaganiu podejmowania decyzji.

2.3.4 Architektura Retrieval-Augmented Generation

Retrieval-Augmented Generation (RAG) jest architekturą łączącą mechanizmy wyszukiwania informacji z możliwościami generacyjnymi dużych modeli językowych. W klasycznym podejściu model językowy generuje odpowiedź wyłącznie na podstawie wiedzy zgromadzonej podczas procesu uczenia (Brown et al., 2020). W architekturze RAG przed wygenerowaniem odpowiedzi wykonywane jest dodatkowe wyszukiwanie dokumentów powiązanych semantycznie z zapytaniem użytkownika. Odnalezione dokumenty są następnie przekazywane do modelu językowego jako dodatkowy kontekst, co pozwala ograniczyć problem halucynacji modeli językowych oraz zwiększyć aktualność generowanych odpowiedzi (Lewis et al., 2020).

2.4 Przegląd istniejących rozwiązań

Interesującym przykładem wykorzystania dużych modeli językowych w obszarze żywienia jest rozwiązanie DietAI24 zaproponowane przez Yan i współautorów (2025). Autorzy opracowali system umożliwiający automatyczną ocenę wartości odżywczej posiłków na podstawie zdjęć żywności. W zaproponowanym podejściu wykorzystano multimodalne duże modele językowe (MLLM) wspomagane architekturą Retrieval-Augmented Generation, która umożliwia odwoływanie się do zewnętrznej bazy wiedzy zawierającej dane żywieniowe pochodzące z Food and Nutrient Database for Dietary Studies (FNDDS). Zastosowanie mechanizmu RAG pozwoliło ograniczyć zależność od wiedzy wewnętrznej modelu oraz zwiększyć dokładność szacowania wartości odżywczych. Autorzy wykazali, że DietAI24 osiąga istotnie lepsze wyniki niż tradycyjne podejścia oparte wyłącznie na metodach komputerowego rozpoznawania obrazu. Przedstawione rozwiązanie potwierdza potencjał integracji dużych modeli językowych z zewnętrznymi źródłami wiedzy w zastosowaniach związanych z analizą żywienia (Yan et al., 2025).

Przykładem zastosowania architektury Retrieval-Augmented Generation w obszarze medycznym jest praca Su i Gu (2024), w której wykorzystano mechanizm RAG do ograniczenia uprzedzeń dużego modelu językowego Llama wobec tradycyjnej medycyny chińskiej. W zaproponowanym rozwiązaniu zgromadzono zewnętrzną bazę wiedzy obejmującą recenzowane artykuły naukowe, wyniki badań klinicznych, metaanalizy oraz historyczne teksty dotyczące tradycyjnej medycyny chińskiej. Zebrane dokumenty zostały poddane przetwarzaniu z wykorzystaniem metod NLP, a następnie zaindeksowane przy użyciu mechanizmu wyszukiwania wektorowego FAISS (Johnson et al., 2021). Podczas generowania odpowiedzi model

Llama otrzymywał dodatkowy kontekst w postaci dokumentów odnalezionych na podstawie zapytania użytkownika. Wyniki eksperymentów wykazały, że zastosowanie architektury RAG pozwoliło zwiększyć dokładność generowanych odpowiedzi, ograniczyć występowanie błędnych informacji oraz zmniejszyć wpływ uprzedzeń obecnych w danych treningowych modelu. Autorzy podkreślają również znaczenie wykorzystania aktualnych i wiarygodnych źródeł wiedzy zewnętrznej, które pozwalają poprawić rzetelność odpowiedzi generowanych przez duże modele językowe (Su & Gu, 2024).

Istotnym kierunkiem rozwoju współczesnych systemów wspomagających pracę naukowców jest wykorzystanie metod generatywnej sztucznej inteligencji do automatyzacji procesu wyszukiwania oraz analizy literatury naukowej. Chodak i Filipek (2025) wskazują, że narzędzia oparte na dużych modelach językowych mogą wspierać badaczy na różnych etapach procesu badawczego, w szczególności podczas wyszukiwania, analizy oraz syntezy publikacji naukowych. Autorzy zwracają uwagę na rosnące znaczenie wyspecjalizowanych narzędzi, takich jak Elicit, Consensus czy NotebookLM, które umożliwiają automatyczne przeszukiwanie literatury, identyfikację najważniejszych informacji oraz generowanie syntetycznych podsumowań wyników badań. Jednocześnie podkreślono konieczność krytycznej oceny wyników generowanych przez modele językowe oraz potrzebę weryfikacji otrzymanych informacji z wykorzystaniem wiedzy eksperckiej. Przedstawione rozwiązania potwierdzają rosnący potencjał metod NLP i dużych modeli językowych w procesie wspomagania analizy literatury naukowej (Chodak & Filipek, 2025).

Przedstawione rozwiązania potwierdzają rosnące znaczenie dużych modeli językowych oraz architektury Retrieval-Augmented Generation w obszarze żywienia i medycyny. Wspólną cechą opisanych systemów jest wykorzystanie zewnętrznych źródeł wiedzy w celu zwiększenia wiarygodności generowanych odpowiedzi oraz ograniczenia problemu halucynacji modeli językowych. W przeciwieństwie do zaprezentowanych prac, opracowany w niniejszej pracy system integruje dane populacyjne pochodzące z badania NHANES z aktualną literaturą naukową pozyskiwaną z bazy PubMed. Celem proponowanego rozwiązania jest nie tylko identyfikacja problemów związanych ze spożyciem składników odżywczych, ale również automatyczne generowanie raportów interpretujących uzyskane wyniki w kontekście aktualnych dowodów naukowych. Zastosowanie dedykowanej bazy wiedzy oraz mechanizmu oceny jakości publikacji pozwala dodatkowo preferować źródła dostarczające silniejszych dowodów naukowych, co zwiększa rzetelność generowanych raportów.

2.5 Architektura bazy wiedzy

Kluczowym elementem opracowanego systemu jest baza wiedzy wykorzystywana podczas generowania raportów. Jej zadaniem jest dostarczanie publikacji naukowych powiązanych z analizowanym problemem żywieniowym. W przeciwieństwie do tradycyjnych rozwiązań

wykorzystujących wyszukiwanie internetowe w czasie rzeczywistym, w opracowanym systemie zastosowano dedykowaną bazę wiedzy przygotowaną na podstawie wcześniej wyselekcjonowanych publikacji naukowych.

Źródłem wiedzy wykorzystanym w projekcie jest baza PubMed, będąca jednym z największych repozytoriów publikacji z zakresu medycyny, zdrowia publicznego oraz nauk o żywieniu (National Library of Medicine, 2025). W celu ograniczenia liczby nieistotnych dokumentów zastosowano zestaw zapytań opartych na terminach MeSH związanych z analizowanymi składnikami odżywczymi. Pozwoliło to na pozyskanie publikacji dotyczących między innymi spożycia błonnika pokarmowego oraz sodu.

Proces budowy bazy wiedzy rozpoczyna się od pobrania metadanych publikacji, takich jak identyfikator PubMed, tytuł, abstrakt, rok publikacji oraz typ artykułu naukowego. Następnie dla każdej publikacji wyznaczana jest wstępna ocena jakości uwzględniająca rodzaj badania oraz aktualność publikacji. Dzięki temu możliwe jest preferowanie bardziej wartościowych źródeł wiedzy podczas późniejszego procesu wyszukiwania.

W kolejnym etapie wykorzystano duży model językowy do wzbogacenia artykułów o dodatkowe metadane. Model analizuje treść abstraktów i identyfikuje między innymi typ badanej populacji, rozróżniając badania prowadzone na ludziach od badań opartych wyłącznie na modelach zwierzęcych. Uzyskane informacje wykorzystywane są podczas wyznaczania końcowej oceny publikacji oraz wspomagają późniejszy proces rankingu wyników wyszukiwania.

Po zakończeniu procesu wzbogacania danych generowane są reprezentacje wektorowe publikacji naukowych. Embeddingi tworzone są na podstawie treści tytułów oraz abstraktów artykułów i stanowią numeryczną reprezentację znaczenia dokumentu. Dzięki temu możliwe jest wyszukiwanie publikacji podobnych semantycznie do analizowanego problemu, nawet jeśli użyte w zapytaniu słowa nie występują bezpośrednio w treści artykułu.

Metadane publikacji oraz odpowiadające im reprezentacje wektorowe przechowywane są w relacyjnej bazie danych PostgreSQL rozszerzonej o moduł pgvector. Rozwiązanie to umożliwia jednocześnie przechowywanie danych opisowych oraz realizację operacji wyszukiwania semantycznego bez konieczności wykorzystywania zewnętrznych baz wektorowych.

Przygotowana w ten sposób baza wiedzy stanowi fundament procesu Retrieval-Augmented Generation wykorzystywanego przez system (Lewis et al., 2020). W momencie generowania raportu odpowiednie publikacje wyszukiwane są na podstawie podobieństwa semantycznego do analizowanego problemu żywieniowego, a następnie przekazywane do modelu językowego jako dodatkowy kontekst wspomagający interpretację wyników analizy.

2.6 Proces generowania raportu

Po przygotowaniu bazy wiedzy możliwe jest generowanie raportów wspomagających interpretację wyników analiz żywieniowych. Proces ten wykorzystuje architekturę Retrieval-Augmented Generation, której zadaniem jest połączenie danych statystycznych pochodzących ze zbioru NHANES z informacjami zawartymi w publikacjach naukowych zgromadzonych w bazie wiedzy.

Proces rozpoczyna się od analizy wyników statystycznych dotyczących wybranego składnika odżywczego. Na podstawie obliczonych statystyk system określa charakter problemu żywieniowego występującego w analizowanej populacji. W zależności od uzyskanych wyników problem może zostać zaklasyfikowany między innymi jako niedobór lub nadmierne spożycie danego składnika.

Po zidentyfikowaniu problemu system buduje zapytanie opisujące analizowaną sytuację. Zapytania są przygotowywane dla wcześniej zdefiniowanych scenariuszy żywieniowych i mają postać krótkich opisów tekstowych wykorzystywanych podczas wyszukiwania semantycznego. Dzięki temu możliwe jest wyszukiwanie publikacji odnoszących się do konkretnego problemu zdrowotnego, a nie wyłącznie do pojedynczych słów kluczowych.

Następnie generowana jest reprezentacja wektorowa zapytania, która wykorzystywana jest do wyszukania najbardziej podobnych semantycznie publikacji w bazie wiedzy. W pierwszym etapie wybierana jest grupa kandydatów o najwyższym podobieństwie do analizowanego problemu. Kolejno wykonywany jest dodatkowy etap rankingu uwzględniający zarówno podobieństwo semantyczne, jak i ocenę jakości publikacji wyznaczoną podczas budowy bazy wiedzy.

Najwyżej ocenione publikacje stanowią kontekst przekazywany do modelu językowego. Oprócz informacji pochodzących z literatury naukowej model otrzymuje również wyniki analizy statystycznej obejmujące między innymi medianę spożycia, wartości percentylowe oraz udział osób należących do poszczególnych kategorii spożycia. Pozwala to na jednoczesne wykorzystanie danych liczbowych oraz wiedzy naukowej podczas generowania odpowiedzi.

W ostatnim etapie model językowy tworzy raport tekstowy zawierający podsumowanie wyników analizy, interpretację zaobserwowanych zjawisk oraz odniesienie do aktualnej literatury naukowej. Raport uzupełniany jest o informacje dotyczące wykorzystanych publikacji, co umożliwia użytkownikowi dalszą weryfikację przedstawionych wniosków.

Zastosowanie architektury Retrieval-Augmented Generation pozwala ograniczyć ryzyko generowania treści niezwiązanych z analizowanym problemem oraz zapewnić, że raport tworzony jest w oparciu o wcześniej przygotowaną bazę wiedzy zawierającą publikacje naukowe związane z żywieniem i zdrowiem publicznym.

2.7 Ograniczenia systemu

Pomimo możliwości automatyzacji części procesu analizy danych żywieniowych opracowane rozwiązanie posiada szereg ograniczeń wynikających zarówno z charakterystyki wykorzystanych danych, jak i zastosowanych metod sztucznej inteligencji.

Pierwszym ograniczeniem jest wykorzystanie danych pochodzących z badania NHANES. Analiza opiera się na deklarowanym przez uczestników spożyciu żywności z jednego dnia badania. Pomimo zastosowania dodatkowych filtrów jakościowych dane te mogą nie odzwierciedlać długoterminowych nawyków żywieniowych poszczególnych osób. Wyniki analizy należy więc interpretować jako przybliżenie rzeczywistego sposobu żywienia badanej populacji.

Kolejne ograniczenie związane jest z zakresem zgromadzonej bazy wiedzy. System wykorzystuje wyłącznie publikacje naukowe pozyskane z bazy PubMed na podstawie wcześniej zdefiniowanych zapytań. Oznacza to, że raporty generowane są wyłącznie w oparciu o wiedzę zawartą w zgromadzonych dokumentach. Publikacje spoza przygotowanej bazy wiedzy nie są uwzględniane podczas procesu wyszukiwania i generowania odpowiedzi.

Ograniczenia wynikają również z wykorzystania dużych modeli językowych. Pomimo zastosowania architektury Retrieval-Augmented Generation modele językowe mogą generować odpowiedzi zawierające uproszczenia lub interpretacje nie w pełni zgodne z intencją autora publikacji naukowej. Z tego względu wygenerowane raporty powinny być traktowane jako narzędzie wspomagające analizę, a nie jako źródło ostatecznych decyzji eksperckich.

Istotnym ograniczeniem jest również sposób budowy zapytań wykorzystywanych podczas wyszukiwania publikacji. W obecnej wersji systemu wykorzystywany jest zestaw wcześniej przygotowanych scenariuszy odpowiadających określonym problemom żywieniowym. Rozwiązanie to upraszcza proces wyszukiwania, jednak ogranicza elastyczność systemu w przypadku bardziej złożonych lub nietypowych analiz.

Należy również podkreślić, że obecna wersja rozwiązania została przygotowana dla wybranych składników odżywczych. Rozszerzenie systemu o kolejne składniki wymaga przygotowania odpowiednich zapytań do bazy PubMed, rozbudowy bazy wiedzy oraz zdefiniowania dodatkowych scenariuszy analitycznych.

Pomimo przedstawionych ograniczeń opracowany system pokazuje możliwość skutecznego połączenia danych populacyjnych, literatury naukowej oraz metod Retrieval-Augmented Generation w celu wspomagania procesu analizy spożycia składników odżywczych. Rozwiązanie może stanowić podstawę do dalszego rozwoju narzędzi wspierających pracę analityków zdrowia publicznego i specjalistów z zakresu żywienia.

3 Implementacja systemu

Pierwszym etapem implementacji systemu było przygotowanie bazy wiedzy wykorzystywanej podczas generowania raportów. W tym celu pobrano publikacje naukowe z bazy PubMed, a następnie zapisano ich metadane w relacyjnej bazie danych PostgreSQL.

Po pobraniu artykułów zaimplementowano mechanizm oceny jakości publikacji naukowych. Celem tego etapu było preferowanie badań dostarczających bardziej wiarygodnych dowodów naukowych. W systemie wykorzystano punktację opartą na rodzaju publikacji (Wykaz 3.1).

Wykaz 3.1 : Punktacja typów publikacji naukowych

```
SCORE_MAP = {  
    "Meta-Analysis": 5,  
    "Systematic Review": 4,  
    "Randomized Controlled Trial": 4,  
    "Review": 3,  
    "Journal Article": 1  
}
```

Najwyższą ocenę otrzymują metaanalizy oraz przeglądy systematyczne, ponieważ stanowią one najwyższy poziom dowodów naukowych. Niższą punktację przyznano pojedynczym artykułom naukowym. Oprócz rodzaju publikacji uwzględniono również aktualność badań. Nowsze publikacje otrzymują dodatkowe punkty zwiększające ich znaczenie podczas późniejszego procesu wyszukiwania (Wykaz 3.2).

Tak wyznaczona wartość `quality_score` stanowi podstawową ocenę jakości publikacji wykorzystywaną przez kolejne etapy systemu.

Ocena jakości publikacji została rozszerzona o dodatkowe informacje pozyskiwane automatycznie przy użyciu dużego modelu językowego. Zadaniem modelu było przeanalizowanie abstraktu artykułu i określenie rodzaju badanej populacji. W systemie przyjęto trzy możliwe klasy (Wykaz 3.3).

Najwyższą ocenę otrzymują badania prowadzone na ludziach, ponieważ są one najbardziej przydatne z punktu widzenia analizy zdrowia publicznego. Badania wykorzystujące

Wykaz 3.2 : Algorytm uwzględniający rok publikacji

```
year_bonus = 0

if year:
    age = CURRENT_YEAR - year

    if age <= 4:
        year_bonus = 2
    elif age <= 7:
        year_bonus = 1
    else:
        year_bonus = 0

total_quality_score = type_score + year_bonus
```

Wykaz 3.3 : Punktacja typu populacji badawczej

```
POPULATION_SCORE_MAP = {
    "human": 2,
    "animal": 1,
    "unknown": 0
}
```

wyłącznie modele zwierzęce otrzymują niższą punktację, natomiast artykuły, dla których nie udało się jednoznacznie określić rodzaju populacji, nie otrzymują dodatkowych punktów. Końcowa ocena publikacji wyznaczana jest poprzez połączenie oceny jakości publikacji oraz punktacji przyznanej przez model językowy.

Dzięki temu podczas późniejszego wyszukiwania preferowane są publikacje nie tylko wysokiej jakości, ale również bardziej użyteczne z punktu widzenia analiz dotyczących zdrowia człowieka. Po zakończeniu procesu wzbogacania metadanych dla każdej publikacji generowana jest reprezentacja wektorowa wykorzystywana przez mechanizm wyszukiwania semantycznego. Na potrzeby tworzenia embeddingów połączono tytuł oraz abstrakt publikacji w pojedynczy dokument tekstowy (Wykaz 3.4).

Tak przygotowany tekst przekazywany jest do modelu embeddingowego, który generuje reprezentację numeryczną opisującą znaczenie publikacji. Wektory zapisywane są w bazie PostgreSQL z wykorzystaniem rozszerzenia pgvector. Podczas generowania raportu system tworzy embedding zapytania opisującego analizowany problem żywieniowy. Następ-

Wykaz 3.4 : Budowa tekstu wejściowego dla modelu embeddingowego

```
def build_embedding_text(row):  
    return f"""  
Title:  
{row.title}  
  
Abstract:  
{row.abstract}  
"""
```

nie wykonywane jest wyszukiwanie semantyczne wśród zapisanych wektorów publikacji. Uzyskane wyniki są dodatkowo sortowane z uwzględnieniem wcześniej wyznaczonej oceny jakości artykułu. Takie podejście pozwala jednocześnie uwzględniać znaczenie publikacji względem analizowanego problemu oraz wartość naukową danego źródła.

W celu udostępnienia funkcjonalności systemu zaimplementowano interfejs REST API wykorzystujący framework FastAPI (Ramirez, 2025). Interfejs pełni rolę warstwy komunikacyjnej pomiędzy użytkownikiem a poszczególnymi modułami systemu. Po otrzymaniu żądania API uruchamia moduł analizy statystycznej, następnie inicjuje proces wyszukiwania publikacji naukowych, a na końcu wywołuje generator raportów. Wynik zwracany jest do użytkownika w postaci ustrukturyzowanej odpowiedzi zawierającej statystyki oraz wygenerowany raport. Zastosowanie architektury API umożliwia łatwą integrację systemu z aplikacjami webowymi oraz dalszą rozbudowę rozwiązania o nowe funkcjonalności bez konieczności modyfikacji istniejących komponentów.

3.1 Weryfikacja działania systemu

W celu oceny poprawności działania opracowanego rozwiązania przeprowadzono testy wykorzystujące dwa scenariusze odpowiadające analizowanym składnikom odżywczym: błonnikowi pokarmowemu oraz sodowi. Celem eksperymentów było sprawdzenie, czy system jest w stanie poprawnie zidentyfikować problem żywieniowy, odnaleźć odpowiednie publikacje naukowe oraz wygenerować raport zawierający interpretację wyników opartą na literaturze naukowej.

W pierwszym scenariuszu wykorzystano wyniki analizy spożycia błonnika przedstawione w Rozdziale 1. Na podstawie wyznaczonych statystyk system zidentyfikował dominujący problem niedostatecznego spożycia błonnika w analizowanej populacji. W związku z tym

uruchomiony został scenariusz wyszukiwania publikacji naukowych dotyczących konsekwencji zdrowotnych niedoboru błonnika pokarmowego. Po wygenerowaniu zapytania moduł Retrieval przeprowadził wyszukiwanie semantyczne w bazie wiedzy. Następnie wykonano dodatkowy etap rankingu uwzględniający zarówno podobieństwo semantyczne publikacji do analizowanego problemu, jak i ocenę jakości wyznaczoną podczas budowy bazy wiedzy.

Tabela 3.1: Publikacje naukowe zwrócone przez moduł Retrieval dla scenariusza niedoboru błonnika

PMID	Typ publikacji	Ocena	Similarity
40651334	Systematic Review	8	0.615
40537680	RCT	8	0.564
41459804	RCT	8	0.558

Źródło: opracowanie własne na podstawie publikacji (Haas et al., 2025; Kalkeren et al., 2026; Veronese et al., 2025).

Analiza wyników (Tabela 3.1) wskazuje, że wszystkie zwrócone publikacje dotyczyły wpływu spożycia błonnika na zdrowie człowieka. Wśród najwyższej ocenionych artykułów znalazły się metaanalizy, przeglądy systematyczne oraz badania prowadzone na populacji ludzkiej, co potwierdza poprawność działania zastosowanego mechanizmu rankingu. Na podstawie odnalezionych publikacji oraz wyników analizy statystycznej model językowy wygenerował raport interpretujący zaobserwowane zjawisko.

2. Evidence From Literature

An umbrella review (PMID: 40651334) synthesizing data from over 17 million individuals confirms that higher dietary fiber intake is convincingly associated with reduced risk of cardiovascular disease (CVD) mortality, pancreatic cancer, and diverticular disease. Additional evidence suggests fiber intake lowers all-cause mortality and coronary heart disease risk. Another randomized study (PMID: 40537680) demonstrated that fiber supplementation can reduce gut microbial production of trimethylamine-N-oxide (TMAO), a metabolite linked to increased CVD risk, particularly in individuals with lower habitual meat consumption. Furthermore, a controlled trial (PMID: 41459804) highlights that fermentable fiber improves insulin sensitivity and metabolic health by modulating gut microbiota and increasing beneficial short-chain fatty acid production.

Wygenerowany raport poprawnie odnosił się do problemu niedostatecznego spożycia błonnika oraz wskazywał potencjalne konsekwencje zdrowotne wynikające z utrzymywania się tego

zjawiska. Dodatkowo raport zawierał odwołania do publikacji naukowych wykorzystanych podczas procesu generowania odpowiedzi.

Drugi scenariusz dotyczył analizy spożycia sodu. Podobnie jak w przypadku błonnika wykorzystano wyniki analizy statystycznej przedstawione wcześniej w pracy. Na podstawie uzyskanych rezultatów system zaklasyfikował analizowany problem jako nadmierne spożycie sodu występujące w znacznej części badanej populacji. W kolejnym kroku uruchomiony został proces wyszukiwania publikacji naukowych związanych z konsekwencjami nadmiernego spożycia sodu. Mechanizm Retrieval przeprowadził wyszukiwanie semantyczne, a następnie wykonał dodatkowy ranking wyników uwzględniający ocenę jakości publikacji.

Tabela 3.2: Publikacje naukowe zwrócone przez moduł Retrieval dla scenariusza nadmiernego spożycia sodu

PMID	Typ publikacji	Ocena	Similarity
37721034	Review	7	0.587
40651890	Review	7	0.568
38545804	Review	7	0.566

Źródło: opracowanie własne na podstawie publikacji (Bailey & Dhaun, 2024; Nishimoto et al., 2024; Zoccali et al., 2025).

Zwrócone publikacje (Tabela 3.2) koncentrowały się na wpływie nadmiernego spożycia sodu na zdrowie człowieka, ze szczególnym uwzględnieniem chorób układu sercowo-naczyniowego oraz nadciśnienia tętniczego. Podobnie jak w poprzednim scenariuszu najwyższe pozycje zajmowały publikacje posiadające wysoką ocenę jakości naukowej. Na podstawie wyników wyszukiwania oraz danych statystycznych system wygenerował raport opisujący analizowany problem.

- Public Health Implications Given that over three-quarters of the population exceed sodium intake recommendations, there is a heightened risk of hypertension, cardiovascular disease, and premature mortality. The high prevalence of salt sensitivity amplifies these risks, particularly among older adults and individuals with comorbidities such as obesity. Excessive sodium intake contributes to increased healthcare burden due to hypertension-related complications.

Raport poprawnie identyfikował potencjalne zagrożenia zdrowotne związane z nadmiernym spożyciem sodu oraz odnosił się do aktualnej literatury naukowej zgromadzonej w bazie wiedzy.

Analiza wyników wyszukiwania przeprowadzona dla obu scenariuszy wskazuje, że mechanizm Retrieval skutecznie identyfikuje publikacje związane z analizowanym problemem żywieniowym. W obu przypadkach zwrócone artykuły dotyczyły bezpośrednio badanego składnika odżywczego oraz jego wpływu na zdrowie człowieka. Dodatkowe wykorzystanie oceny jakości publikacji pozwoliło preferować źródła dostarczające silniejszych dowodów naukowych. Wśród najwyżżej ocenionych wyników dominowały metaanalizy, przeglądy systematyczne oraz badania prowadzone na ludziach. Oznacza to, że zastosowany mechanizm rankingu skutecznie ograniczał wpływ publikacji o niższej wartości poznawczej.

Przeprowadzona weryfikacja potwierdziła możliwość wykorzystania architektury Retrieval-Augmented Generation do wspomagania analizy spożycia składników odżywczych. Najważniejszą zaletą opracowanego rozwiązania jest automatyczne łączenie danych statystycznych pochodzących z badania NHANES z aktualną literaturą naukową. Dzięki temu użytkownik otrzymuje nie tylko wyniki liczbowe, ale również ich interpretację opartą na publikacjach naukowych. Istotną zaletą systemu jest również zastosowanie dedykowanej bazy wiedzy oraz mechanizmu oceny jakości publikacji. Pozwala to ograniczyć wpływ mniej wartościowych źródeł oraz zwiększa prawdopodobieństwo wykorzystania badań dostarczających silniejszych dowodów naukowych.

Jednocześnie należy uwzględnić ograniczenia rozwiązania. Jakość generowanych raportów zależy od jakości zgromadzonej bazy wiedzy oraz poprawności działania modelu językowego. Ponadto obecna wersja systemu została przygotowana dla ograniczonej liczby składników odżywczych i wymaga dalszej rozbudowy w celu obsługi szerszego zakresu analiz. W przyszłości system może zostać rozszerzony o kolejne składniki odżywcze, automatyczną aktualizację bazy wiedzy oraz bardziej zaawansowane mechanizmy oceny jakości publikacji naukowych. Możliwe jest również opracowanie interfejsu użytkownika umożliwiającego wykorzystanie rozwiązania przez osoby nieposiadające wiedzy technicznej.

3.2 Podsumowanie rozdziału

W niniejszym rozdziale przedstawiono implementację oraz weryfikację działania opracowanego systemu wspomagania analizy spożycia składników odżywczych. Zaimplementowano kompletny proces obejmujący budowę bazy wiedzy na podstawie publikacji naukowych pozyskanych z bazy PubMed, ocenę jakości artykułów, generowanie reprezentacji wektorowych oraz mechanizm wyszukiwania semantycznego wykorzystujący architekturę Retrieval-Augmented Generation. Przeprowadzone eksperymenty potwierdziły poprawność działania poszczególnych komponentów systemu. Mechanizm Retrieval skutecznie identyfikował publikacje naukowe związane z analizowanym problemem żywieniowym, natomiast zastosowany model językowy generował raporty uwzględniające zarówno wyniki analizy statystycznej

danych NHANES, jak i informacje pochodzące z literatury naukowej. W ramach weryfikacji działania rozwiązania przeanalizowano dwa scenariusze obejmujące spożycie błonnika pokarmowego oraz sodu. W obu przypadkach system poprawnie identyfikował dominujący problem żywieniowy, wyszukiwał odpowiednie publikacje naukowe oraz generował raport zawierający interpretację uzyskanych wyników.

Najważniejszym rezultatem pracy jest opracowanie działającego prototypu systemu łączącego dane populacyjne, bazę wiedzy opartą na publikacjach naukowych oraz możliwości dużych modeli językowych. Uzyskane wyniki wskazują, że architektura Retrieval-Augmented Generation może stanowić skuteczne narzędzie wspomagające analizę danych żywieniowych oraz proces interpretacji wyników w obszarze zdrowia publicznego. Przedstawione rozwiązanie może stanowić podstawę do dalszego rozwoju systemów wspierających pracę analityków zdrowia publicznego, dietetyków oraz badaczy zajmujących się oceną sposobu żywienia populacji.

Podsumowanie

Celem niniejszej pracy było opracowanie systemu wspomagającego analizę spożycia składników odżywczych z wykorzystaniem metod Retrieval-Augmented Generation. W ramach realizacji projektu połączono dane żywieniowe pochodzące z badania NHANES z bazą wiedzy utworzoną na podstawie publikacji naukowych pozyskanych z bazy PubMed. Opracowane rozwiązanie umożliwia automatyczną analizę danych populacyjnych, wyszukiwanie literatury naukowej związanej z analizowanym problemem oraz generowanie raportów wspierających interpretację uzyskanych wyników.

W pierwszej części pracy przedstawiono problematykę zdrowia publicznego oraz znaczenie analizy danych żywieniowych. Omówiono również charakterystykę wykorzystanego zbioru danych NHANES oraz proces przygotowania danych do dalszych analiz. Przeprowadzona eksploracyjna analiza danych pozwoliła zidentyfikować problemy związane ze spożyciem błonnika pokarmowego oraz sodu w analizowanej populacji.

W dalszej części zaprojektowano architekturę systemu opartą na metodzie Retrieval-Augmented Generation. Opracowane rozwiązanie obejmuje moduł analizy statystycznej, bazę wiedzy opartą na publikacjach naukowych, mechanizm wyszukiwania semantycznego oraz generator raportów wykorzystujący duży model językowy. Szczególną uwagę poświęcono procesowi oceny jakości publikacji naukowych oraz sposobowi ich wykorzystania podczas generowania odpowiedzi.

W ramach implementacji utworzono kompletny prototyp systemu umożliwiający analizę danych żywieniowych oraz automatyczne generowanie raportów. Przeprowadzone testy wykazały, że system poprawnie identyfikuje problemy żywieniowe, wyszukuje powiązane publikacje naukowe oraz tworzy raporty zawierające interpretację wyników opartą na aktualnej literaturze naukowej.

Uzyskane rezultaty pozwalają pozytywnie odpowiedzieć na postawione w pracy pytanie badawcze. Zastosowanie architektury Retrieval-Augmented Generation umożliwia skuteczne połączenie wyników analizy statystycznej z wiedzą pochodzącą z publikacji naukowych, wspierając proces interpretacji danych dotyczących sposobu żywienia populacji. Opracowany system może stanowić narzędzie wspomagające pracę analityków zdrowia publicznego oraz specjalistów zajmujących się oceną stanu odżywienia społeczeństwa.

Należy jednak podkreślić, że przedstawione rozwiązanie posiada również pewne ograniczenia. Obecna wersja systemu obsługuje wyłącznie wybrane składniki odżywcze, a jakość generowanych raportów zależy od jakości zgromadzonej bazy wiedzy oraz poprawności działania modelu językowego. Ponadto system nie zastępuje wiedzy eksperckiej i powinien być traktowany jako narzędzie wspomagające proces analizy.

W przyszłości możliwe jest rozszerzenie rozwiązania o kolejne składniki odżywcze, automatyczną aktualizację bazy wiedzy, bardziej zaawansowane metody oceny jakości publikacji oraz interfejs użytkownika umożliwiający wykorzystanie systemu przez osoby nieposiadające wiedzy technicznej. Interesującym kierunkiem dalszych badań może być również porównanie jakości generowanych raportów z analizami przygotowywanymi przez ekspertów z zakresu żywienia i zdrowia publicznego.

4 Bibliografia

- Bailey, M. A., & Dhaun, N. (2024). Salt Sensitivity: Causes, Consequences, and Recent Advances. *Hypertension*, 81(3), 476–489. <https://doi.org/10.1161/HYPERTENSIONAHA.123.17959>
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., et al. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*.
- Centers for Disease Control and Prevention. (n.d.). *National Health and Nutrition Examination Survey (NHANES)*. <https://www.cdc.gov/nchs/nhanes/index.html>
- Chodak, J., & Filipek, K. (2025). *Generatywna sztuczna inteligencja (Gen AI) w badaniach naukowych. Przewodnik po inteligentnych narzędziach i rozwiązaniach*. Wydawnictwo Uniwersytetu Marii Curie-Skłodowskiej. https://www.researchgate.net/publication/392237059_Generatywna_sztuczna_inteligencja_Gen_AI_w_badaniach_naukowych
- Haas, M., Brandl, B., Neuhaus, K., Wudy, S., Kleigrew, K., Hauner, H., & Skurk, T. (2025). Effect of Dietary Fiber on Trimethylamine-N-Oxide Production After Beef Consumption and on Gut Microbiota: MEATMARK - A Randomized Cross-Over Study. *European Journal of Clinical Nutrition*, 79(10), 980–990. <https://doi.org/10.1038/s41430-025-01636-8>
- Johnson, J., Douze, M., & Jégou, H. (2021). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*. <https://doi.org/10.1109/TBDDATA.2019.2921572>
- Jurafsky, D., & Martin, J. H. (2025). *Speech and Language Processing* (3. wyd.). <https://web.stanford.edu/~jurafsky/slp3/>
- Kalkeren, C. A. J. van, Deuren, T. van, Coenjaerts, M. M. J., Galazzo, G., Barnett, D. J. M., Penders, J., Hartmann, B., Holst, J. J., Canfora, E. E., & Blaak, E. E. (2026). Effects of a Slowly Fermentable Fiber Mixture Against the Background of a High-Protein Diet on Insulin Sensitivity and Metabolic Health in Individuals With Overweight: A Randomized, Placebo-Controlled Trial. *Gut Microbes*, 18(1), 2606473. <https://doi.org/10.1080/19490976.2025.2606473>
- Katz, A. (2025). *pgvector: Open-source Vector Similarity Search for PostgreSQL*. <https://github.com/pgvector/pgvector>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *arXiv preprint arXiv:2005.11401*.

- National Center for Health Statistics. (2017). *NHANES Demographic Variables and Sample Weights (DEMO_J)*. https://www.cdc.gov/Nchs/Data/Nhanes/Public/2017/DataFiles/DEMO_J.htm
- National Center for Health Statistics. (2018). *Dietary Interview - Total Nutrient Intakes, First Day (DR1TOT_J)*. https://www.cdc.gov/Nchs/Data/Nhanes/Public/2017/DataFiles/DR1TOT_J.htm
- National Library of Medicine. (2025). *PubMed*. <https://pubmed.ncbi.nlm.nih.gov>
- Nishimoto, M., Griffin, K. A., Wynne, B. M., & Fujita, T. (2024). Salt-Sensitive Hypertension and the Kidney. *Hypertension*, 81(6), 1206–1217. <https://doi.org/10.1161/HYPERTENSIONAHA.123.21369>
- OpenAI. (2025). *Embeddings Guide*. <https://platform.openai.com/docs/guides/embeddings>
- PostgreSQL Global Development Group. (2025). *PostgreSQL Documentation*. <https://www.postgresql.org/docs/>
- Ramirez, S. (2025). *FastAPI Documentation*. <https://fastapi.tiangolo.com>
- Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *arXiv preprint arXiv:1908.10084*.
- Su, X., & Gu, Y. (2024). *Implementing Retrieval-Augmented Generation (RAG) for Large Language Models to Build Confidence in Traditional Chinese Medicine*. ResearchGate. https://www.researchgate.net/publication/381354790_Implementing_Retrieval-Augmented_Generation_RAG_for_Large_Language_Models_to_Build_Confidence_in_Traditional_Chinese_Medicine
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*.
- Veronese, N., Gianfredi, V., Solmi, M., Barbagallo, M., Dominguez, L. J., Mandalà, C., Di Palermo, C., Carruba, L., Solimando, L., Stubbs, B., Castagna, A., Maggi, S., Zanetti, M., Al-Daghri, N., Sabico, S., Nucci, D., Gosling, C., & Fontana, L. (2025). The Impact of Dietary Fiber Consumption on Human Health: An Umbrella Review of Evidence from 17,155,277 Individuals. *Clinical Nutrition*, 51, 325–333. <https://doi.org/10.1016/j.clnu.2025.06.021>
- World Health Organization. (2023). *Carbohydrate intake guidelines (fat and carbohydrate update)*. <https://www.who.int/news/item/17-07-2023-who-updates-guidelines-on-fats-and-carbohydrates>
- World Health Organization. (2026). *Sodium reduction: key facts*. <https://www.who.int/news-room/fact-sheets/detail/sodium-reduction>
- Yan, R., Luo, H., Lu, J., Liu, D., Posluszny, H., Dhaliwal, M. P., MacLeod, J., Qin, Y., Yang, C., Hartman, T. J., & Hu, X. (2025). DietAI24 as a Framework for Comprehensive Nutrition Estimation Using Multimodal Large Language Models. *Communications Medicine*. <https://doi.org/10.1038/s43856-025-01159-0>
- Zipf, G., Chiappa, M., Porter, K. S., Ostchega, Y., Lewis, B. G., & Dostal, J. (2013). *National Health and Nutrition Examination Survey: Plan and Operations, 1999–2010*

- (Nr 56; Vital i Health Statistics. Series 1, Programs i Collection Procedures). National Center for Health Statistics; U.S. Department of Health; Human Services, Centers for Disease Control; Prevention.
- Zoccali, C., Mallamaci, F., D'Elia, L., Galletti, F., & Strazzullo, P. (2025). Salt Sensitivity of Blood Pressure: From Renal Mechanisms to Immune and Inflammatory Pathways. *Nutrition, Metabolism and Cardiovascular Diseases*, 35(11), 104194. <https://doi.org/10.1016/j.numecd.2025.104194>