



UCZELNIA LUDZI CIEKAWYCH

Studia podyplomowe Big Data — Analytics & Society

BARTOSZ PRZYBYSZ

Projekt i implementacja systemu wspomagania analizy spożycia składników odżywczych z wykorzystaniem metod Retrieval-Augmented Generation

Na przykładzie danych NHANES oraz literatury
naukowej pozyskanej z bazy PubMed

Praca dyplomowa

Promotor: dr Łukasz Wawrowski

Poznań 2026

Spis treści

1. Wstęp	5
2. Charakterystyka problemu oraz danych	6
2.1. Wprowadzenie do problematyki zdrowia publicznego i żywienia	6
2.2. Problem badawczy	7
2.3. Cel i zakres pracy	7
2.4. Charakterystyka zbioru NHANES	8
2.4.1. Charakterystyka badania NHANES	8
2.4.2. Wykorzystane źródła danych	9
2.4.3. Charakterystyka zamienionych wykorzystanych w projekcie	9
2.4.4. Charakterystyka końcowego zbioru danych	9
2.4.5. Uzasadnienie wyboru danych	10
2.5. Przygotowanie danych	10
2.5.1. Weryfikacja jakości danych	10
2.5.2. Łączenie zbiorów danych	10
2.5.3. Przygotowanie zmiennych pomocniczych	11
2.5.4. Filtr przygotowujący najbardziej wiarygodne dane	11
2.5.5. Budowa końcowego zbioru analitycznego	11
2.5.6. Podsumowanie procesu przygotowania	12
2.6. Ekspolaryjna analiza danych	12
3. Wybrana metoda statystyczna	13
3.1. Metoda 1	13
3.2. Metoda 2	13
4. Przeprowadzona analiza	14
4.1. Przygotowanie danych	14
4.2. Zastosowanie algorytmu	14
4.3. Rezultaty	14
5. Podsumowanie	15
6. Bibliografia	16

Załączniki	17
A. Kod wykorzystany w analizie	17

Spis rycin

Spis tabel

1. Wstęp

Celem pracy jest zaprojektowanie i implementacja systemu wspomagania analizy składników odżywczych na poziomie populacyjnym z wykorzystaniem metod Retrieval-Augmented Generation (RAG), dużych modeli językowych oraz literatury naukowej pozyskiwanej z bazy PubMed. Opracowany system umożliwi identyfikację niedoborów i nadmiarów wybranych składników odżywczych na podstawie danych żywieniowych, automatyczne wyszukiwanie powiązanych publikacji naukowych oraz generowanie raportów wspierających proces podejmowania decyzji przez analityków zdrowia publicznego i żywienia. W ramach pracy zaprojektowano architekturę obejmującą pozyskiwanie i przetwarzanie danych naukowych, budowę bazy wiedzy wykorzystującej wyszukiwanie semantyczne oraz generowanie raportów opartych na danych statystycznych i aktualnych dowodach naukowych.

Zakres pracy obejmuje: * analizę możliwości wykorzystania metod Retrieval-Augmented Generation w obszarze zdrowia publicznego * opracowanie procesu pozyskiwania i przetwarzania publikacji naukowych z PubMed * budowę bazy i wiedzy wykorzystującej reprezentacje wektorowe artykułów naukowych * implementację mechanizmu wyszukiwania i rankingu publikacji * implementację modułu analizy danych żywieniowych * implementację aplikacji umożliwiającej generowanie raportów wspomagających ocenę spożycia składników odżywczych * weryfikację działania systemu na przykładzie danych NHANES

2. Charakterystyka problemu oraz danych

2.1. Wprowadzenie do problematyki zdrowia publicznego i żywienia

Odżywianie jest nieodłącznym elementem życia. Człowiek musi jeść by przeżyć. Wraz z pokarmem, człowiek powinien dostarczać odpowiedniej ilości energii oraz składników odżywczych. Jest to niezbędne do prawidłowego funkcjonowania procesów biologicznych, utrzymania sprawności organizmu oraz zmniejszania ryzyka występowania wielu chorób przewlekłych. Zarówno niedobory, jak i nadmiary składników odżywczych mogą prowadzić do negatywnych konsekwencji zdrowotnych, które często ujawniają się po wielu latach.

Współczesne społeczeństwa mają dostęp do coraz większej ilości informacji dotyczących zdrowego stylu życia oraz zasad prawidłowego żywienia. Pomimo tego nieprawidłowe nawyki żywieniowe nadal pozostają istotnym problemem zdrowia publicznego. Niewłaściwa dieta jest uznawana za jeden z czynników ryzyka wielu schorzeń, takich jak choroby układu krążenia, cukrzyca typu 2, nadciśnienia tętnicze czy otyłość. Z tego względu monitorowanie sposobu żywienia społeczeństwa stanowi ważny element działań podejmowanych przez instytucje zajmujące się zdrowiem publicznym.

Ocena stanu odżywiania populacji wymaga gromadzenia oraz analizy dużych ilości danych dotyczących spożycia żywności i składników odżywczych. W tym celu prowadzone są badania populacyjne pozwalające na identyfikację najczęściej występujących problemów żywieniowych oraz obserwację zmian zachodzących w czasie. Wyniki takich analiz mogą stanowić podstawę do opracowywania programów edukacyjnych, kampanii profilaktycznych oraz rekomendacji żywieniowych kierowanych do różnych grup społecznych.

Wraz ze wzrostem ilości dostępnych danych rośnie znaczenie narzędzi informatycznych wspomagających proces ich analizy. Nowoczesne metody analizy danych umożliwiają identyfikację trendów żywieniowych, wykrywanie nieprawidłowości oraz wspieranie ekspertów w procesie podejmowania decyzji. Szczególnego znaczenia nabierają rozwiązania wykorzystujące sztuczną inteligencję oraz automatyczne przetwarzanie informacji naukowej, które mogą przyspieszyć interpretację wyników i ułatwić dostęp do aktualnej wiedzy medycznej.

2.2. Problem badawczy

Pomimo dostępności dużych zbiorów danych żywieniowych oraz obszernej literatury naukowej, proces identyfikacji problemów żywieniowych i ich interpretacji nadal wymaga znacznego nakładu pracy ekspertów. Analitycy zdrowia publicznego oraz specjaliści z zakresu żywienia muszą nie tylko analizować dane dotyczące spożycia składników odżywczych, ale również interpretować wyniki w kontekście aktualnej wiedzy naukowej. W praktyce oznacza to konieczność równoczesnej pracy z danymi statystycznymi oraz przeglądania licznych publikacji naukowych.

Analiza dużych zbiorów danych populacyjnych pozwala na identyfikację niedoborów i nadmiarów składników odżywczych występujących w określonych grupach społecznych. Samo wykrycie problemu nie jest jednak wystarczające do sformułowania wniosków oraz rekomendacji. Konieczne jest również odniesienie wyników do aktualnych badań naukowych opisujących potencjalne skutki zdrowotne obserwowanych zjawisk. Proces ten jest czasochłonny i wymaga specjalistycznej wiedzy zarówno z zakresu żywienia, jak i wyszukiwania oraz oceny jakości literatury naukowej.

Dodatkowym wyzwaniem jest dynamiczny wzrost liczby publikacji naukowych. Bazy takie jak PubMed zawierają miliony artykułów, a każdego roku publikowane są kolejne tysiące prac dotyczących zdrowia i żywienia człowieka. W efekcie ręczne wyszukiwanie najbardziej istotnych publikacji oraz synteza zawartych w nich informacji stają się coraz bardziej wymagające.

Rozwój metod sztucznej inteligencji, w szczególności dużych modeli językowych (Large Language Models, LLM), stwarza nowe możliwości wspomagania procesu analizy danych oraz interpretacji wyników. Szczególne zainteresowanie budzą rozwiązania wykorzystujące architekturę Retrieval-Augmented Generation (RAG), która pozwala łączyć generowanie tekstu przez model językowy z informacjami pochodzącymi z zewnętrznej bazy wiedzy. Takie podejście umożliwia tworzenie raportów opartych zarówno na danych wejściowych, jak i aktualnej literaturze naukowej.

W związku z przedstawionymi wyzwaniami sformułowano następujące pytanie badawcze: **W jaki sposób można wykorzystać architekturę Retrieval-Augmented Generation do wspomagania analizy spożycia składników odżywczych oraz generowania raportów opartych na danych żywieniowych i literaturze naukowej?**

2.3. Cel i zakres pracy

Celem niniejszej pracy jest zaprojektowanie oraz implementacja systemu wspomagania analizy spożycia składników odżywczych z wykorzystaniem metod Retrieval-Augmented

Generation. Opracowane rozwiązanie ma wspierać analityków zdrowia publicznego w identyfikacji niedoborów i nadmiarów składników odżywczych występujących w badanej populacji oraz dostarczać informacje oparte na aktualnej literaturze naukowej.

W ramach pracy opracowano system umożliwiający analizę danych żywieniowych, automatyczne wykrywanie problemów związanych ze spożyciem wybranych składników odżywczych oraz generowanie raportów wspomagających proces interpretacji wyników. Generowane raporty łączą informacje pochodzące z analizowanego zbioru danych z wiedzą pozyskiwaną z publikacji naukowych.

Istotnym elementem systemu jest wykorzystanie architektury Retrieval-Augmented Generation, która umożliwia wspomaganie procesu generowania raportów za pomocą zewnętrznej bazy wiedzy. W ramach projektu utworzono dedykowaną bazę wiedzy opartą na publikacjach naukowych pozyskanych z bazy PubMed. Artykuły zostały poddane procesowi selekcji, wzbogacenia o dodatkowe metadane oraz przygotowania do wyszukiwania semantycznego.

Zakres pracy obejmuje przygotowanie danych żywieniowych, budowę bazy wiedzy, implementację mechanizmu wyszukiwania publikacji naukowych, implementację modułu generowania raportów oraz stworzenie interfejsu programistycznego umożliwiającego korzystanie z systemu. Działanie rozwiązania zostało zweryfikowane na przykładzie danych pochodzących z programu National Health and Nutrition Examination Survey (NHANES).

Praca koncentruje się na demonstracji możliwości wykorzystania metod Retrieval-Augmented Generation w obszarze zdrowia publicznego. Opracowany system ma charakter narzędzia wspomagającego podejmowanie decyzji i nie zastępuje oceny dokonywanej przez specjalistów z zakresu zdrowia publicznego oraz żywienia.

2.4. Charakterystyka zbioru NHANES

2.4.1. Charakterystyka badania NHANES

NHANES (National Health and Nutrition Examination Survey) to ogólnokrajowe badanie zdrowia i stanu odżywiania populacji prowadzone w Stanach Zjednoczonych. Program jest realizowany przez National Center for Health Statistics, będąc częścią Centers for Disease Control and Prevention (CDC). Badanie zostało uruchomione na początku lat 60. XX wieku, natomiast od 1999 roku jest prowadzone w sposób ciągły. Głównym celem NHANES jest monitorowanie stanu zdrowia społeczeństwa amerykańskiego. NHANES łączy dane pochodzące z wywiadów ankietowych, badań lekarskich oraz analiz laboratoryjnych. Zbierane są informacje dotyczące między innymi demografii, sposobu odżywiania, aktywności fizycznej i występowania chorób. Badanie obejmuje reprezentatywną próbę mieszkańców Stanów Zjednoczonych. Dzięki temu uzyskane wyniki mogą być uogólniane na całą populację

kraju. NHANES wyróżnia się wysoką jakością danych oraz standaryzacja procesu ich zbierania. Z tego względu jest jednym z najczęściej wykorzystywanych źródeł danych w badaniach epidemiologicznych, medycznych i z zakresu zdrowia publicznego.

2.4.2. Wykorzystane źródła danych

W ramach projektu wykorzystano dwa zbiory danych pochodzące z cyku NHANES 2017-2018: * DEMO_J * DR1TOT_J

Tabela DEMO_J zawiera informacje demograficzne dotyczące uczestników badania, takie jak wiek oraz płeć. Z kolei tabela DR1TOT_J zawiera dane dotyczące spożycia składników odżywczych uzyskane na podstawie pierwszego 24-godzinnego wywiadu żywieniowego (Day 1 Total Nutrient Intakes). Połączenie obu zbiorów umożliwia analizę spożycia składników odżywczych w kontekście cech demograficznych badanej populacji.

2.4.3. Charakterystyka zmiennych wykorzystanych w projekcie

W projekcie wykorzystano wybrane zmienne niezbędne do przeprowadzenia analiz żywieniowych oraz budowy systemu wspomagania decyzji. * SEQN - unikalny identyfikator uczestnika badania * RIAGENDR - płeć uczestnika * RIDAGEYR - wiek uczestnika w latach * DR1DRSTZ - status wiarygodności wywiadu żywieniowego * DR1MRESP - osoba odpowiadająca na pytania ankietowe * DR1HELP - informacja o pomocy udzielanej podczas wywiadu * DR1TKCAL - dzienne spożycie energii [kcal] * DR1TFIBE - dzienne spożycie błonnika (g) * DR1TSODI - dzienne spożycie sodu (mg)

Przedstawione zmienne zostały wykorzystane podczas przygotowania danych oraz dalszej analizy spożycia składników odżywczych.

2.4.4. Charakterystyka końcowego zbioru danych

Oba zbiory danych zostały połączone przy wykorzystaniu identyfikatora uczestnika SEQN. W wyniku połączenia uzyskano zbiór zawierający 8704 obserwacje. Każda obserwacja reprezentuje pojedynczego uczestnika badania.

Otrzymany zbiór stanowi podstawę dalszych etapów przetwarzania danych, tworzenia zmiennych pomocniczych oraz analiz przedstawionych w kolejnych częściach pracy.

2.4.5. Uzasadnienie wyboru danych

Zbiór NHANES został wybrany ze względu na wysoką jakość danych, szeroki zakres gromadzonych informacji oraz powszechne wykorzystanie w badaniach naukowych. Dane zawierają szczegółowe informacje dotyczące spożycia składników odżywczych, co umożliwia przeprowadzenie analiz związanych z identyfikacją niedoborów i nadmiarów żywieniowych.

Dodatkową zaletą jest możliwość łączenia informacji pochodzących z różnych modułów badania przy wykorzystaniu wspólnego identyfikatora uczestnika. Pozwala to na tworzenie bardziej kompleksowych zbiorów danych oraz rozszerzenie analiz o kolejne aspekty zdrowia i żywienia w przyszłych etapach rozwoju systemu.

2.5. Przygotowanie danych

2.5.1. Weryfikacja jakości danych

Przed rozpoczęciem analizy przeprowadzono kontrolę jakości danych. Zweryfikowano występowanie zduplikowanych rekordów oraz brakujących wartości.

```
day_1.duplicated().sum()
demo.duplicated().sum()

day_1.isnull().sum()
demo.isnull().sum()
```

Nie wykryto zduplikowanych obserwacji w żadnym z analizowanych zbiorów danych. Przeprowadzona analiza brakujących wartości wykazała ich zgodność z dokumentacją NHANES. Występujące braki wynikały ze sposobu projektowania badania oraz logiki ankiety, a nie z błędów podczas gromadzenia danych.

2.5.2. Łączenie zbiorów danych

W pierwszym etapie przygotowania danych połączono tabele DEMO_J oraz DR1TOT_J. Obie tabele zawierają wspólny identyfikator uczestnika badania oznaczony jako SEQN, który został wykorzystany jako klucz łączenia.

```
silver_df = silver_day_1.merge(silver_demo, on="SEQN", how="left")
```

W wyniku połączenia uzyskano zbiór zawierający 8704 obserwacje oraz 11 zmiennych.

2.5.3. Przygotowanie zmiennych pomocniczych

Na potrzeby dalszej analizy utworzono zmienną pomocniczą umożliwiającą klasyfikację uczestników badania ze względu na deklarowane dzienne spożycie energii. Celem było zidentyfikowanie obserwacji charakteryzujących się skrajnie niską lub skrajnie wysoką kalorycznością, które mogłyby wpływać na wyniki dalszych analiz.

```
# I determine flag for too low kcal < 800, too high kcal > 5500 and normal between 800 - 5500
silver_df.loc[silver_df["DR1TKCAL"] < 800, "kcal_flag"] = "low_kcal"

silver_df.loc[
    (silver_df["DR1TKCAL"] >= 800) & (silver_df["DR1TKCAL"] <= 5500),
    "kcal_flag"
] = "normal_kcal"

silver_df.loc[silver_df["DR1TKCAL"] > 5500, "kcal_flag"] = "high_kcal"
```

Na potrzeby projektu przyjęto zakres od 800 do 5500 kcal jako przedział reprezentujący typowe dzienne spożycie energii. Obserwacje znajdujące się poza tym zakresem zostały oznaczone jako potencjalnie niereprezentatywne i wykorzystane w dalszym procesie filtrowania danych.

2.5.4. Filtr przygotowujący najbardziej wiarygodne dane

W celu zwiększenia wiarygodności analiz utworzono dodatkowy filtr jakości danych. Pozostawiono wyłącznie obserwacje spełniające określone kryteria jakościowe.

Do dalszej analizy zakwalifikowano uczestników, których wywiad żywieniowy został oznaczony jako wiarygodny przez NHANES, którzy samodzielnie odpowiadali na pytania lub odpowiadali za żywienie gospodarstwa domowego oraz nie wymagali pomocy podczas udzielania odpowiedzi.

Dodatkowo odrzucono obserwacje o skrajnie niskiej lub wysokiej deklarowanej podaży energii. Na potrzeby projektu przyjęto zakres od 800 do 5500 kcal jako przedział reprezentujący typowe dzienne spożycie energii.

2.5.5. Budowa końcowego zbioru analitycznego

Powstanie tabeli wykorzystywanej przez system,

```
gold_df = quality_silver_data.copy()

gold_df.to_sql(
    "nhanes_gold",
    engine,
    index=False,
    if_exists="replace"
)
```

Końcowy zbiór analityczny został zapisany w tabeli `nhanes_gold` i stanowi źródło danych wykorzystywane przez moduł analizy statystycznej systemu

2.5.6. Podsumowanie procesu przygotowania

Proces przygotowania danych obejmował integrację danych demograficznych i żywieniowych, kontrolę jakości danych, filtrowanie obserwacji oraz utworzenie zmiennych pomocniczych wykorzystywanych przez system. W wyniku przeprowadzonych operacji utworzono końcowy zbiór analityczny stanowiący podstawę dalszych analiz oraz działania opracowanego rozwiązania.

2.6. Ekspolaryjna analiza danych

3. Wybrana metoda statystyczna

3.1. Metoda 1

TEKST

Wzory w tekście wstawiamy z wykorzystaniem pojedynczego znaku dolara: $y = ax + b$, natomiast jak chcemy go wycentrować to wtedy używany jest podwójny.

$$c^2 = a^2 + b^2 \tag{3.1}$$

Równanie 3.1 stanowi podstawę współczesnej matematyki.

TEKST

3.2. Metoda 2

W podrozdziale 3.1 przedstawiono pierwszą wersję, natomiast w tym podrozdziale znajdzie się opis jej ulepszenia. Jeżeli nie chcemy wstawiać prefiksu razem z odsyłaczem to poprzedzamy go znakiem minusa.

TEKST

4. Przeprowadzona analiza

```
#kod
```

4.1. Przygotowanie danych

TEKST

```
#kod
```

TEKST

4.2. Zastosowanie algorytmu

W tym miejscu zastosujemy metodę opisaną w podrozdziale [3.1.](#)

TEKST

4.3. Rezultaty

TEKST

```
# kod
```

Tekst

5. Podsumowanie

6. Bibliografia

A. Kod wykorzystany w analizie

```
# kod
```